

From Engine Evaluations to Human Explanations: A Multi-Level LLM Pipeline for Critical Chess Positions

(Von Engine-Bewertungen zu menschlichen Erklärungen: Eine mehrstufige LLM-Pipeline für kritische Schachstellungen)

Bachelor Semester Project S2 (Academic Year 2025/26), University of Luxembourg

Viktor Tsvetkov | viktor.tsvetkov.001@student.uni.lu

Zusammenfassung

Schachengines bewerten Stellungen präzise, doch ihre Ausgabe ist eine einzelne Zahl, die nichts erklärt – und dieselbe Erklärung ist für einen Anfänger und einen Meister nicht gleich nützlich. Dieses Projekt entwickelt und evaluiert eine Pipeline, die eine per Engine bewertete Schachstellung in drei Erklärungen übersetzt, zugeschnitten auf drei Spielstärken: Anfänger (unter 1400 Elo), Vereinsspieler (1400–2200) und Meisterniveau (über 2200).

Die Pipeline nutzt drei Eingaben pro Stellung: die Stellung (FEN), ihre Engine-Bewertung und eine automatisch berechnete Figur-für-Figur-Attribution. Letztere erzeugt die Bibliothek chessplainer, die mittels SHAP den Beitrag jeder Figur zur Gewinnwahrscheinlichkeit von Weiß misst. Als kontrolliertes Vokabular dient eine aus McGrath et al. (2022) rekonstruierte und am Stockfish-8-Quellcode verifizierte Bibliothek von 207 Schachkonzepten.

Abgeschlossene Ziele: (1) Aufbau und Verifikation der Konzeptbibliothek (93 Stockfish-Konzepte plus 114 Zusatzkonzepte). (2) Entwurf des System-Prompts mit drei Zielgruppen, festen Regeln zum Lesen der Bewertung (Weiß-Perspektive; Matt erscheint als extremer Bewertungssprung) und Erdungsregeln gegen erfundene Behauptungen. (3) Mechanische Verifikation des Datensatzes von 25 kritischen Stellungen aus Partien von Fischer und Tal: alle 25 Züge reproduzieren exakt die Folgestellung; die Bewertungen stimmen mit frischer Stockfish-16-Analyse überein (8 von 8 Stichproben). (4) Vollautomatisierte Abfrage eines Sprachmodells: ein Skript stellt genau eine Anfrage pro Stellung; der API-Schlüssel steht nicht im Code. (5) Eine Ergebnisdatei mit vier Spalten (ID plus drei Erklärungen) und die Bewertung jedes Datensatzes auf einer ganzzahligen Likert-Skala 1–5 in vier Dimensionen – Fundiertheit, Klarheit, Treue und Kohärenz –, also zehn Werte pro Datensatz, mit schriftlichem Bewertungsleitfaden.

Von 250 vergebenen Werten liegen 236 bei 5 und 14 bei 4. Wichtiger als die Mittelwerte ist ein methodischer Befund: Der Abgleich jeder Erklärung mit der SHAP-Attribution deckte einen echten sachlichen Fehler auf (ein Läuferpaar war der falschen Seite zugeschrieben), den bloßes Gegenlesen übersehen hatte. Zudem dominieren Schwerfiguren die SHAP-Werte, während didaktisch zentrale Merkmale wie Freibauern niedriger gewichtet sind – treue und lehrreiche Erklärungen müssen beides verbinden. Nächste Schritte: Bewertung unkorrigierter Erstausgaben des Modells, ein zweiter Bewerter mit Übereinstimmungsmaß und die Skalierung über 25 Stellungen hinaus.